Purwakarta, 10 Maret 2026

Research Proposal: Undergraduate Thesis (Mechatronics and Artificial Intelligence)

Nama & NIM	Yudi Pratama Putra		2201306	Mekatronika dan Kecerdasan Buatan

Penguji 1	Liptia Venica, S.T., M.T	
Penguji 2	Muhammad Rizalul Wahhid, S.Si., M.T	

Judul Penelitian

Pengembangan Sistem Deteksi Promosi Judi *Online* Berbahasa Indonesia Berbasis Deep Learning dengan Pendekatan Adversarial Training untuk Mengatasi Manipulasi Unicode

Development of an Indonesian Online Gambling Promotion Detection System Based on Deep Learning with an Adversarial Training Approach to Handle Unicode Manipulation

Tujuan Penelitian

Tujuan dari penelitian ini adalah sebagai berikut:

1. Membangun dataset teks promosi judi *online* berbahasa Indonesia yang dilengkapi dengan variasi manipulasi karakter *Unicode*.
2. Mengembangkan model klasifikasi teks berbasis *deep learning* dengan pendekatan *adversarial training* untuk menghasilkan model yang mampu mengenali teks promosi judi *online* yang telah dimanipulasi menggunakan variasi karakter Unicode.
3. Merancang sistem deteksi promosi judi *online* berupa prototipe *browser extension* dan *REST API* yang terintegrasi dengan model, yang mampu memindai teks pada halaman *web* secara *realtime* dan menyensor konten yang terdeteksi.
4. Mengevaluasi kinerja sistem deteksi yang dikembangkan dalam mendeteksi teks promosi judi *online* yang telah dimanipulasi karakter *Unicode* serta mendukung efektivitas moderasi konten secara *realtime* pada *platform* media sosial.

Rumusan Masalah

Rumusan masalah penelitian ini, yaitu:

1. Bagaimana membangun dataset teks promosi judi *online* berbahasa Indonesia yang dilengkapi dengan variasi manipulasi karakter *Unicode*?

2. Bagaimana mengembangkan model klasifikasi teks berbasis *deep learning* dengan pendekatan *adversarial training* untuk menghasilkan model yang mampu mengenali teks promosi judi *online* yang telah dimanipulasi menggunakan variasi karakter *Unicode*?
3. Bagaimana merancang sistem deteksi promosi judi *online* berupa prototipe *browser extension* dan *REST API* yang terintegrasi dengan model, yang mampu memindai teks pada halaman *web* secara *realtime*?
4. Bagaimana mengevaluasi kinerja model dan sistem deteksi yang dikembangkan dalam mendeteksi teks promosi judi *online* yang telah dimanipulasi karakter *Unicode*?

Batasan Penelitian

Batasan yang dilakukan dalam penelitian ini adalah:

1. Penelitian ini berfokus pada tugas klasifikasi teks *biner*, yaitu membedakan teks yang mengandung promosi judi *online* dan bukan promosi judi *online*.
2. Penelitian ini berfokus pada deteksi teks promosi judi *online* sebagai satu-satunya kategori konten ilegal yang dianalisis.
3. *Dataset* yang digunakan dalam penelitian ini merupakan *dataset* yang disusun secara mandiri, yang terdiri dari teks promosi judi online dan teks bukan promosi judi online yang dikumpulkan dari *public channel* atau grup *Telegram*, komentar *YouTube*, dan *Twitter/X* berbahasa Indonesia dengan target minimal 2000 sampel yang terdistribusi seimbang antara kedua kelas.
4. Proses *preprocessing* teks, khususnya *stemming* bahasa Indonesia, dibatasi hanya menggunakan *library PySastrawi*.
5. Dataset tersebut kemudian dimodifikasi menggunakan variasi karakter *Unicode* untuk merepresentasikan pengaburan teks.
6. Model yang digunakan dalam penelitian ini terbatas pada beberapa model klasifikasi teks berbasis *deep learning*, yaitu CNN, BiLSTM, dan IndoBERT, yang dipilih untuk merepresentasikan pendekatan pemodelan teks berbasis *convolutional*, *sequence modeling*, dan *transformer*.
7. Implementasi model ini dibatasi menggunakan *framework* TensorFlow (Keras API) untuk arsitektur CNN dan BiLSTM, serta PyTorch (*Hugging Face Transformers*) untuk arsitektur IndoBERT,.
8. Pendekatan peningkatan ketahanan model yang diuji dalam penelitian ini terbatas pada metode *adversarial training*, dengan memasukkan data teks yang telah mengalami pengaburan ke dalam proses pelatihan model.
9. Evaluasi performa model dilakukan menggunakan metrik klasifikasi standar, yaitu accuracy, precision, recall, dan F1-score.

10. Penelitian ini tidak membahas aspek lain di luar performa klasifikasi, seperti efisiensi komputasi, optimasi arsitektur model, atau implementasi sistem dalam lingkungan produksi.
11. Sistem deteksi diimplementasikan dalam bentuk prototipe *browser extension* dan REST API menggunakan arsitektur *client-server* yang dibatasi pada penggunaan FastAPI sebagai *backend* dan standar Manifest V3 (MV3) untuk *frontend* ekstensi.
12. Fungsionalitas sistem difokuskan pada pemindaian teks secara otomatis dan *realtime* pada elemen *Document Object Model* (DOM) di platform Telegram Web, YouTube, dan Twitter/X, serta penerapan manipulasi visual (penyensoran atau *blur*) pada teks promosi judi online beserta penyorotan (*highlight*) manipulasi *Unicode*.
13. Sistem *browser extension* yang dikembangkan bersifat prototipe (*Proof of Concept*) untuk tujuan demonstrasi penelitian dan tidak dioptimalkan untuk perilisan di lingkungan produksi publik.

Latar Belakang

Perkembangan teknologi internet dan platform digital telah meningkatkan secara signifikan aktivitas komunikasi berbasis teks dalam kehidupan sehari-hari (Raharjo dkk., 2024; Subramanian dkk., 2023). Berbagai layanan daring memungkinkan pengguna berinteraksi dan berbagi informasi dengan cepat dalam skala besar (Kaur dkk., 2024; Subramanian dkk., 2023). Namun, peningkatan ini juga diikuti oleh semakin banyaknya konten yang melanggar aturan atau merugikan, seperti promosi judi *online* (Kaur dkk., 2024; Raharjo dkk., 2024). Promosi judi online ini sangat agresif membanjiri berbagai platform media sosial (Prasetya Kristiadi & Samuel, 2025). Oleh karena itu, diperlukan sistem otomatis yang mampu mendeteksi dan menyaring konten tersebut secara cepat dan akurat untuk mendukung moderasi konten yang efektif (Subramanian dkk., 2023).

Untuk mengatasi permasalahan tersebut, pendekatan *deep learning* dalam *Natural Language Processing* (NLP) seperti CNN, LSTM, dan BERT kini dominan digunakan karena terbukti efektif mendeteksi konten berbahaya secara otomatis (Purnamadewi & Zahra, 2025; Raharjo dkk., 2024; Subramanian dkk., 2023). Dalam konteks judi online (judol), pendekatan ini sangat sesuai karena teks promosinya memiliki pola linguistik yang khas dan konsisten, seperti penggunaan istilah "bonus", "deposit", "slot", atau "gacor" (Prasetya Kristiadi & Samuel, 2025). Namun, untuk menghindari deteksi sistem NLP, agen judol aktif melakukan manipulasi teks tingkat karakter (misalnya menulis "sl0t" atau "jud1"). Hal ini menjadikan promosi judi online sebagai studi kasus yang paling relevan untuk meneliti kelemahan sistem deteksi otomatis terhadap manipulasi *Unicode*.

Untuk mengatasi permasalahan tersebut, berbagai penelitian memanfaatkan pendekatan

Natural Language Processing (NLP) untuk analisis dan klasifikasi teks secara otomatis (Purnamadewi & Zahra, 2025; Raharjo dkk., 2024). Dalam perkembangannya, metode berbasis *deep learning* menjadi dominan karena mampu mempelajari representasi bahasa secara lebih mendalam dibandingkan metode tradisional (Purnamadewi & Zahra, 2025; Subramanian dkk., 2023). Arsitektur seperti *Convolutional Neural Network* (CNN), *Long Short-Term Memory* (LSTM), serta model *Transformer* seperti BERT terbukti memiliki performa tinggi dalam mendeteksi berbagai jenis konten berbahaya (Subramanian dkk., 2023). Dalam konteks judol, pendekatan *deep learning* sangat sesuai karena promosi judol memiliki pola bahasa dan ciri linguistik yang khas serta konsisten, seperti penggunaan istilah "bonus", "deposit", "slot", atau "gacor" (Prasetya Kristiadi & Samuel, 2025). Namun, untuk menghindari deteksi sistem NLP, para agen judol secara aktif melakukan manipulasi teks atau *obfuscation* tingkat karakter (misalnya menulis "sl0t" atau "jud1"). Hal ini menjadikan promosi judi online sebagai studi kasus yang paling relevan untuk meneliti kelemahan sistem deteksi otomatis terhadap manipulasi *Unicode*.

Meskipun model *deep learning* menunjukkan performa tinggi dalam klasifikasi teks pada kondisi normal, berbagai penelitian menunjukkan bahwa sistem NLP masih rentan terhadap manipulasi pada level karakter (Chen & Ji, 2022). Perubahan kecil seperti penggantian huruf dengan simbol serupa, penyisipan karakter, atau variasi ejaan umumnya tidak memengaruhi pemahaman manusia (Cooper dkk., 2025; Shah, 2025). Namun, hal ini dapat menyebabkan model gagal mengenali pola yang telah dipelajari sehingga menurunkan akurasi secara signifikan (Shah, 2025). Hal ini menunjukkan adanya kesenjangan antara kemampuan manusia dan model dalam memahami teks yang telah dimodifikasi (Boucher dkk., 2021).

Salah satu bentuk manipulasi teks yang semakin umum digunakan adalah pengaburan teks (*text obfuscation*) melalui variasi karakter *Unicode* (Boucher dkk., 2021; Cooper dkk., 2025; Sarabamoun, 2025). Teknik ini memanfaatkan karakter yang secara visual mirip dengan huruf biasa namun memiliki representasi kode berbeda, termasuk penggunaan karakter serupa dan penyisipan karakter tak terlihat (Boucher dkk., 2021; Cooper dkk., 2025; Sarabamoun, 2025). Bagi manusia, teks yang dimodifikasi dengan cara ini umumnya masih dapat dibaca dan dipahami dengan mudah (Boucher dkk., 2021; Sarabamoun, 2025). Namun, bagi sistem NLP, perubahan kecil pada level karakter tersebut dapat mengganggu proses pemrosesan teks, seperti proses *tokenization* atau pembentukan representasi kata, sehingga berpotensi menyebabkan kesalahan dalam proses klasifikasi (Boucher dkk., 2021; Cooper dkk., 2025; Sarabamoun, 2025).

Tabel 1 Penelitian terdahulu yang relevan

Judul dan Peneliti	**Ringkasan Penelitian**	**Hasil Penelitian**	**Limitasi Penelitian**
Deteksi Teks	Penelitian ini	Hasil evaluasi	Penelitian ini

Promosi Judi Online Menggunakan Ai Dengan Kombinasi NLP Dan *Deep learning* (Prasetya Kristiadi & Samuel, 2025)	mengembangkan sistem klasifikasi teks untuk mendeteksi promosi judi online menggunakan teknik NLP dan model seperti Naïve Bayes, SVM, serta *Transformer* berbasis IndoBERT. Dataset berasal dari komentar *YouTube* yang dilabeli menjadi dua kelas, yaitu teks promosi judi dan non-judi.	menunjukkan bahwa model berbasis *Transformer* khususnya IndoBERT memberikan performa terbaik dengan akurasi sekitar 97%, dengan nilai *precision* dan *recall* yang seimbang dalam mendeteksi teks promosi judi online.	berfokus pada klasifikasi teks normal tanpa mempertimbangkan manipulasi karakter atau teknik *text obfuscation* yang sering digunakan untuk menyamarkan teks berbahaya sehingga menghindari sistem deteksi otomatis.
Deep learning-based approaches for abusive content detection and classification for multi-class online user-generated data (Kaur dkk., 2024)	Penelitian ini mengembangkan sistem deteksi bahasa ofensif pada media sosial menggunakan model *deep learning* seperti LSTM, BiLSTM, dan GRU. Dataset terdiri dari 14.200 tweet berbahasa Inggris dengan beberapa kategori klasifikasi. Proses meliputi *preprocessing*, ekstraksi fitur TF-IDF, dan pelatihan model untuk klasifikasi teks.	Hasil penelitian menunjukkan bahwa model *deep learning* mencapai performa tinggi, dengan akurasi pelatihan hingga 99% dan akurasi data uji sekitar 78,65% pada model GRU, serta mampu mengidentifikasi berbagai kategori bahasa ofensif dengan baik.	Penelitian ini masih terbatas pada fitur teks tingkat kata (*word-level*) dan belum mempertimbangkan manipulasi karakter seperti *text obfuscation* atau penggunaan *Unicode* untuk menyamarkan teks berbahaya.
Prediction and Detection of Scam Threats on Digital Platforms for Indonesian Users Using Machine Learning	Penelitian ini mengembangkan model *machine learning* untuk mendeteksi pesan penipuan (*scam*) dengan memanfaatkan pola bahasa dan perilaku pengguna. Dataset dikumpulkan dari survei pengguna di Indonesia	Hasil evaluasi menunjukkan bahwa model Random Forest memberikan performa terbaik dengan akurasi 92,5%, precision 90,7%, recall 94,1%, dan F1-score 92,4%,	Penelitian ini masih terbatas pada model *machine learning* tradisional dan belum mengeksplorasi *deep learning* seperti LSTM atau *Transformer* yang

Models (Raharjo dkk., 2024)	dan diproses melalui *preprocessing* seperti *tokenization*, *normalization*, serta representasi fitur menggunakan TF-IDF dan *word embedding*. Model yang digunakan adalah Random Forest dan SVM untuk klasifikasi pesan *scam* dan non-*scam*.	sehingga lebih efektif dibandingkan model SVM dalam mendeteksi ancaman scam pada *dataset* penelitian.	berpotensi meningkatkan performa. Selain itu, penelitian ini juga belum mempertimbangkan manipulasi karakter seperti manipulasi *Unicode*.
Bad Characters: Imperceptible NLP Attacks (Boucher dkk., 2021)	Penelitian ini mengkaji kerentanan sistem NLP terhadap manipulasi karakter yang tidak terlihat oleh manusia. Peneliti mengembangkan beberapa teknik manipulasi teks seperti penyisipan karakter tak terlihat, penggunaan *homoglyph*, serta perubahan urutan karakter untuk menghasilkan contoh teks *adversarial* yang masih dapat dipahami manusia tetapi dapat mengganggu sistem NLP.	Hasil eksperimen menunjukkan bahwa hanya dengan satu manipulasi karakter yang tidak terlihat oleh pengguna, performa berbagai sistem NLP dapat menurun secara signifikan. Bahkan dengan tiga manipulasi karakter saja, banyak sistem NLP dapat gagal melakukan klasifikasi dengan benar.	Penelitian ini berfokus pada eksplorasi kerentanan model NLP terhadap manipulasi karakter dan belum membahas secara mendalam metode peningkatan ketahanan model seperti teknik *adversarial training*.
Adversarial Attacks in NLP for Abuse Detection Systems (Shah, 2025)	Penelitian ini menganalisis kerentanan sistem deteksi konten berbahaya berbasis *machine learning* dan *deep learning* terhadap serangan *adversarial* pada teks. Peneliti menguji beberapa teknik manipulasi teks seperti perubahan karakter yang menyerupai huruf asli atau	Hasil penelitian menunjukkan bahwa manipulasi karakter sederhana dapat menurunkan akurasi model hingga sekitar 20% dan mampu menghindari sistem deteksi meskipun masih dapat	Penelitian ini berfokus pada analisis kerentanan model terhadap serangan *adversarial* dan belum membahas pendekatan yang efektif untuk meningkatkan

	penggantian huruf dengan simbol yang mirip secara visual.	dipahami manusia.	ketahanan model terhadap manipulasi karakter.
Perturbations in the Wild: Leveraging Human-Written Text Perturbations for Realistic Adversarial Attack and Defense (Le dkk., 2022)	Penelitian ini mengkaji kerentanan model *deep learning* dalam tugas NLP terhadap manipulasi teks yang menyerupai variasi penulisan manusia. Peneliti mengembangkan metode bernama *ANTHRO* yang memanfaatkan ratusan ribu variasi perubahan teks dari data dunia nyata untuk menghasilkan contoh teks *adversarial* yang tetap mempertahankan makna asli namun dapat menyesatkan model klasifikasi teks.	Hasil eksperimen menunjukkan bahwa manipulasi kecil pada teks dapat menyebabkan kesalahan klasifikasi pada berbagai model *Transformer* seperti BERT dan RoBERTa. Metode yang diusulkan mampu mencapai tingkat keberhasilan serangan sekitar 83% pada model BERT, meskipun teks yang dihasilkan tetap mudah dipahami oleh manusia.	Penelitian ini berfokus pada pengembangan metode serangan berbasis manipulasi teks dan evaluasi kerentanan model NLP, namun belum membahas secara mendalam penerapan teknik pertahanan seperti *adversarial training* untuk meningkatkan ketahanan model terhadap manipulasi teks.
Special-Character Adversarial Attacks on Open-Source Language Models (Sarabamoun, 2025)	Penelitian ini mengkaji berbagai teknik serangan berbasis karakter khusus terhadap model bahasa modern. Teknik yang dianalisis mencakup manipulasi karakter *Unicode*, serangan *homoglyph*, serta manipulasi struktur karakter dalam teks untuk menghasilkan contoh *adversarial*.	Hasil eksperimen menunjukkan bahwa manipulasi karakter berbasis *Unicode* dan *homoglyph* dapat menyebabkan kesalahan prediksi pada model bahasa modern dan menimbulkan risiko keamanan pada sistem NLP yang digunakan dalam aplikasi nyata.	Penelitian ini berfokus pada evaluasi kerentanan model terhadap berbagai jenis manipulasi karakter dan belum secara mendalam membahas metode pertahanan terhadap serangan tersebut.

Fast Adversarial Training against Textual Adversarial Attacks (Yang dkk., 2024)	Penelitian ini mengusulkan metode pertahanan terhadap serangan *adversarial* pada sistem NLP menggunakan pendekatan *adversarial training* melalui metode *Fast Adversarial Training* (FAT). Metode ini menghasilkan *adversarial perturbation* pada representasi *embedding* teks menggunakan teknik *single-step gradient ascent*, kemudian melatih model dengan data yang telah diperturbasi untuk meningkatkan ketahanan tanpa memerlukan informasi linguistik tambahan.	Hasil eksperimen menunjukkan bahwa metode *Fast Adversarial Training* meningkatkan ketahanan model BERT terhadap berbagai serangan *adversarial* dan menghasilkan performa yang lebih baik dibandingkan metode pertahanan lainnya pada beberapa dataset.	Penelitian ini berfokus pada peningkatan ketahanan model terhadap serangan *adversarial* menggunakan *adversarial training*, namun masih terbatas pada dataset berbahasa Inggris dan belum mengkaji manipulasi karakter berbasis *Unicode* atau *homoglyph*.
SCAT: Robust Self-supervised Contrastive Learning via Adversarial Training for Text Classification (Wu & Yeung, 2023)	Penelitian ini mengusulkan framework *Self-supervised Contrastive Learning via Adversarial Training* (SCAT) untuk meningkatkan ketahanan model NLP terhadap serangan *adversarial*. Metode ini menghasilkan *adversarial examples* tanpa label dengan memodifikasi token menggunakan model bahasa, yang kemudian digunakan dalam pelatihan berbasis *contrastive learning* untuk menghasilkan representasi teks yang lebih robust.	Hasil eksperimen menunjukkan bahwa SCAT meningkatkan ketahanan model terhadap serangan seperti TextFooler dan BERT-Attack, dengan peningkatan *attack failure rate* hingga sekitar 24% dibandingkan model *baseline* dan penurunan performa pada data bersih yang relatif kecil.	Penelitian ini menggunakan dataset berbahasa Inggris seperti AG News dan DBPedia sehingga belum mengevaluasi efektivitas metode pada teks berbahasa Indonesia. Selain itu, penelitian ini berfokus pada manipulasi token atau kata dan belum secara khusus membahas manipulasi karakter berbasis *Unicode*

			atau *homoglyph*.
Adversarial Training for Improving Model Robustness? Look at Both Prediction and Interpretation (Chen & Ji, 2022)	Penelitian ini mengusulkan metode *Feature-Level Adversarial Training (FLAT)* untuk meningkatkan ketahanan model NLP terhadap serangan *adversarial* berbasis substitusi kata. Metode ini melatih model menggunakan pasangan teks asli dan teks *adversarial* serta menambahkan regularisasi pada tingkat fitur untuk menjaga konsistensi pentingnya kata dalam proses prediksi. Pendekatan ini bertujuan agar model menghasilkan prediksi yang konsisten serta menggunakan alasan yang sama dalam membuat keputusan pada teks asli maupun teks yang telah dimodifikasi.	Hasil eksperimen menunjukkan bahwa metode *FLAT* mampu meningkatkan ketahanan berbagai model NLP seperti *LSTM*, *CNN*, *BERT*, dan *DeBERTa* terhadap serangan *adversarial* seperti *TextFooler* dan *PWWS*. Model yang dilatih menggunakan metode ini menunjukkan peningkatan *after-attack accuracy* serta konsistensi interpretasi yang lebih baik dibandingkan model yang dilatih menggunakan *adversarial training* tradisional.	Penelitian ini menggunakan *dataset* berbahasa Inggris seperti *SST-2*, *IMDB*, *AG News*, dan *TREC* sehingga belum mengevaluasi efektivitas metode yang diusulkan pada *dataset* berbahasa Indonesia. Selain itu, penelitian ini berfokus pada manipulasi teks berbasis substitusi kata dan belum secara khusus mengkaji manipulasi karakter berbasis *Unicode* atau *homoglyph*.

Berdasarkan Tabel 1, pendekatan *deep learning* telah banyak digunakan untuk mendeteksi berbagai konten berbahaya seperti promosi judi online, bahasa ofensif, dan penipuan. Model seperti LSTM, GRU, serta *Transformer* seperti BERT menunjukkan performa klasifikasi yang tinggi pada teks normal. Penerapan IndoBERT menghasilkan akurasi tinggi dalam deteksi promosi judi pada media sosial (Prasetya Kristiadi & Samuel, 2025). Model LSTM dan GRU juga terbukti efektif dalam mendeteksi bahasa ofensif pada data media sosial (Kaur dkk., 2024). Selain itu, model klasifikasi pada kasus penipuan di Indonesia menunjukkan hasil yang cukup baik dalam membedakan pesan penipuan dan normal (Raharjo dkk., 2024). emuan ini menunjukkan bahwa *deep learning* mampu memahami pola bahasa dan konteks semantik secara efektif dalam klasifikasi teks.

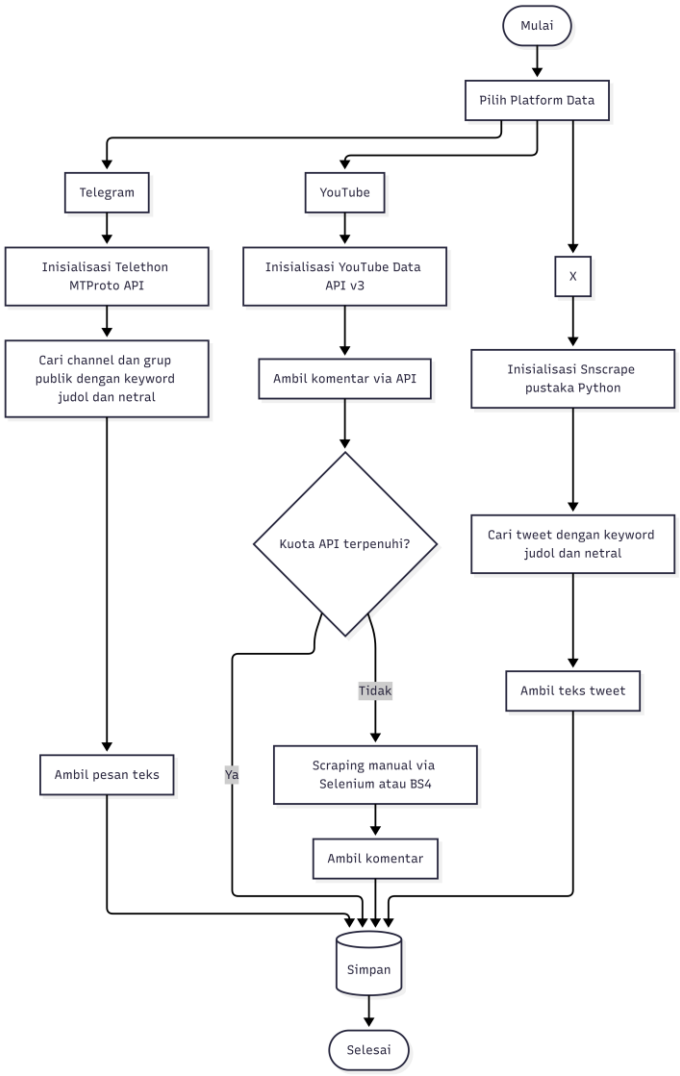
Namun, model NLP modern masih rentan terhadap manipulasi teks pada tingkat karakter. Perubahan kecil seperti *homoglyph*, penyisipan karakter tak terlihat, atau variasi penulisan dapat menyebabkan model gagal mengenali pola yang telah dipelajari. Manipulasi yang tidak terlihat bahkan dapat menurunkan performa secara signifikan meskipun tetap mudah dipahami manusia (Boucher dkk., 2021). Selain itu, serangan *adversarial* berbasis manipulasi karakter juga dapat menurunkan akurasi dan dimanfaatkan untuk menghindari sistem deteksi otomatis (Shah, 2025).

Berbagai penelitian mengeksplorasi serangan berbasis karakter seperti manipulasi *Unicode* dan penggunaan karakter khusus untuk menghasilkan teks *adversarial*. Variasi penulisan yang menyerupai kesalahan manusia terbukti dapat memicu kesalahan prediksi pada model *Transformer* seperti BERT dan RoBERTa (Le dkk., 2022). Selain itu, manipulasi *Unicode* dan *homoglyph* dapat menyebabkan prediksi yang keliru serta menimbulkan risiko keamanan pada sistem NLP (Sarabamoun, 2025). Hal ini menunjukkan bahwa model yang dilatih hanya pada teks normal cenderung memiliki ketahanan rendah terhadap manipulasi karakter.

Sebagai respons terhadap permasalahan tersebut, berbagai pendekatan dikembangkan untuk meningkatkan ketahanan model terhadap serangan *adversarial*, salah satunya melalui *adversarial training*. Pendekatan ini melatih model dengan kombinasi data asli dan data yang dimodifikasi agar mampu memahami variasi teks dan menjadi lebih robust. Metode *Fast Adversarial Training* terbukti meningkatkan ketahanan model BERT terhadap berbagai serangan (Yang dkk., 2024). Pendekatan lain seperti *Self-supervised Contrastive Learning via Adversarial Training* dan *Feature-Level Adversarial Training* juga menunjukkan peningkatan ketahanan model terhadap manipulasi teks (Chen & Ji, 2022; Wu & Yeung, 2023). Namun, sebagian besar penelitian masih berfokus pada manipulasi berbasis kata atau token dan menggunakan dataset berbahasa Inggris.

Berdasarkan berbagai temuan tersebut, masih terdapat celah penelitian yang signifikan. Mayoritas penelitian menggunakan *dataset* berbahasa Inggris, sehingga efektivitas manipulasi karakter *Unicode* pada teks berbahasa Indonesia belum banyak dikaji. Selain itu, penelitian deteksi judi *online* di Indonesia umumnya belum mempertimbangkan manipulasi karakter sebagai upaya menghindari sistem deteksi otomatis, dan pendekatan adversarial training untuk menghadapi *Unicode obfuscation* pada konteks ini belum pernah dieksplorasi secara spesifik. Oleh karena itu, penelitian ini mengembangkan sistem deteksi teks promosi judi *online* berbahasa Indonesia yang tahan terhadap manipulasi karakter *Unicode* menggunakan *adversarial training*.

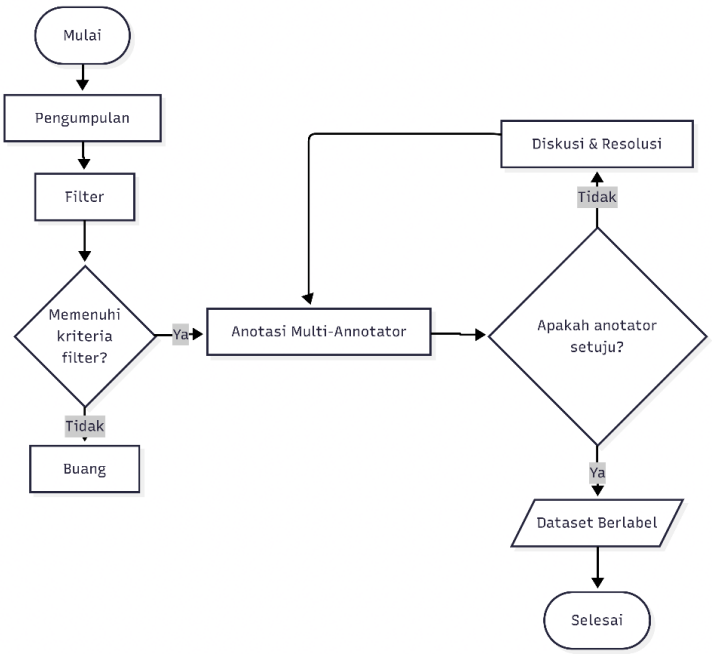
Diagram Blok Sistem



Gambar 1 Alur pengumpulan data

Gambar 1 menyajikan alur pengumpulan data dari tiga platform media sosial, yaitu *Telegram*, *YouTube*, dan *Twitter/X*. Proses dimulai dengan inisialisasi alat yang sesuai untuk masing-masing platform. Pada *Telegram*, peneliti menggunakan pustaka *Telethon* untuk mencari *channel* dan grup publik berdasarkan kata kunci promosi *judol* serta kata kunci netral sebagai pembanding. Pada *YouTube*, peneliti memanfaatkan *YouTube Data API v3* untuk mencari video berdasarkan kata kunci serupa, kemudian mengambil komentar dari video tersebut. Pada *Twitter/X*, pengumpulan data dilakukan menggunakan pustaka *Snscrape* untuk mencari dan mengambil teks *tweet* berdasarkan kata kunci judi online dan kata kunci netral.

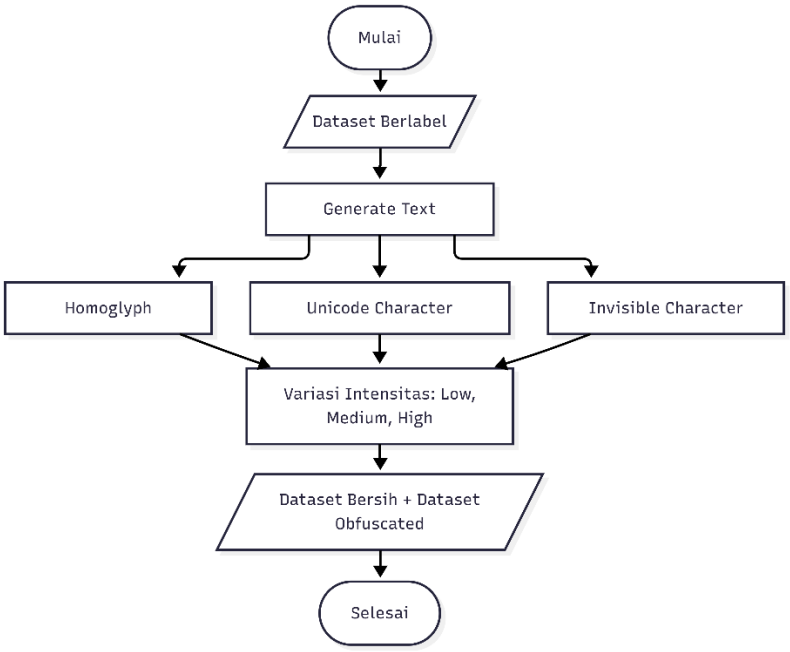
Setelah pencarian dilakukan, alur dilanjutkan dengan proses pengambilan data. Untuk *YouTube*, jika kuota *API* harian terpenuhi, komentar diambil secara normal. Namun, apabila kuota *API* habis atau terjadi kesalahan, alur akan beralih ke *scraping* manual menggunakan *Selenium* atau *BeautifulSoup* (BS4) sebagai alternatif untuk tetap mengambil komentar yang dibutuhkan. Seluruh data yang berhasil dikumpulkan dari ketiga platform (pesan teks Telegram, komentar YouTube, dan teks tweet) kemudian disimpan.



Gambar 2 Dataset Pipeline

Gambar 2 menggambarkan alur pengumpulan data sesuai gambar 1 dan anotasi *dataset* penelitian. Proses dimulai dari pengumpulan teks dari sumber daring yang relevan, yaitu *public channel Telegram*, komentar *YouTube*, dan *Twitter/X* berbahasa Indonesia. Data yang terkumpul kemudian melewati tahap filter awal untuk menghapus data yang tidak memenuhi kriteria, mencakup teks duplikat, teks terlalu pendek (kurang dari 4 kata), teks tidak berbahasa Indonesia, serta konten yang hanya berupa tautan URL tanpa teks pendukung. Data yang tidak lolos *filter* langsung dibuang, sementara data yang lolos diteruskan ke tahap anotasi.

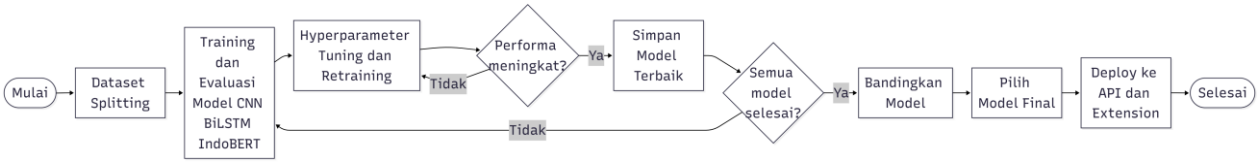
Proses anotasi dilakukan oleh dua *anotator* secara independen mengacu pada pedoman pelabelan yang telah disusun sebelumnya. Setiap teks dikategorikan ke dalam dua label, yaitu Promosi Judol apabila teks mengandung indikasi promosi judi online, atau Non Promosi Judol apabila tidak ditemukan indikasi tersebut. Hasil label kedua *anotator* kemudian dibandingkan. Apabila keduanya sepakat, data langsung masuk ke dataset berlabel. Apabila terjadi ketidaksepakatan, kedua *anotator* melakukan diskusi hingga mencapai kesepakatan, yang kemudian dikembalikan ke proses anotasi untuk difinalisasi. Kualitas keseluruhan proses anotasi diukur menggunakan *Cohen's Kappa* sebagai metrik *Inter-Annotator Agreement* (IAA).



Gambar 3 Text Obfuscation Generation

Gambar 3 menggambarkan alur pembuatan variasi teks *obfuscation*. Proses dimulai dari *dataset* berlabel (berisi promosi judol dan bukan promosi judol) yang telah disiapkan pada tahap sebelumnya. *Dataset* tersebut kemudian diproses menggunakan teknik manipulasi karakter berbasis *Unicode*, seperti *homoglyph substitution*, *Unicode character substitution*, serta penyisipan karakter tidak terlihat (*invisible character insertion*).

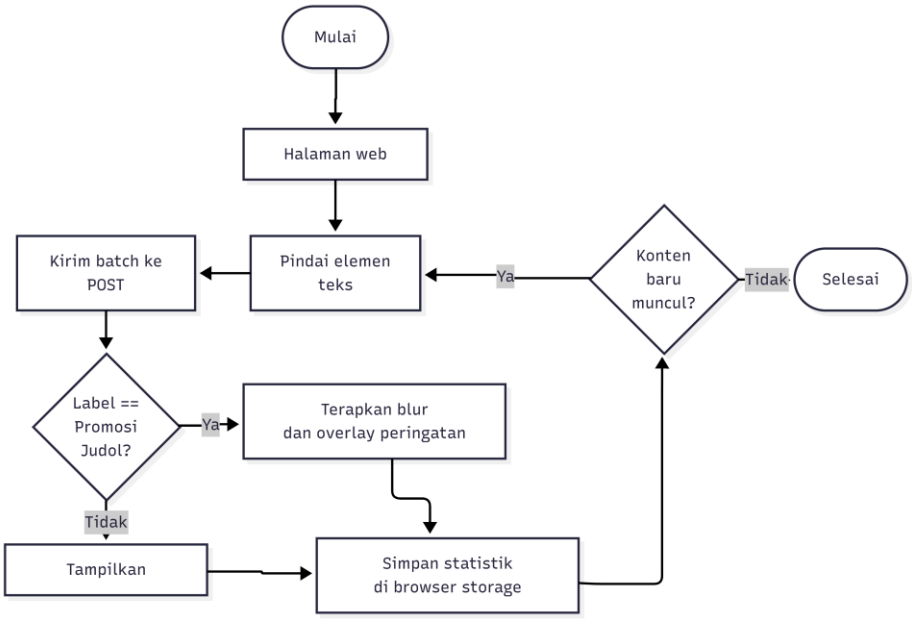
Untuk mengevaluasi ketahanan model secara terukur, masing-masing dari ketiga teknik tersebut diterapkan dalam tiga tingkat intensitas berdasarkan persentase jumlah karakter yang dimanipulasi. Tingkat *low* merepresentasikan manipulasi ringan (15% karakter), tingkat *medium* untuk manipulasi sedang (30% karakter), dan tingkat *high* untuk manipulasi ekstrem (50% karakter atau lebih) di mana teks mengalami distorsi maksimal oleh sistem namun secara visual masih dapat dibaca oleh manusia. Penerapan teknik dan intensitas ini menghasilkan sembilan variasi *dataset obfuscated* secara keseluruhan. Hasil akhir dari tahap ini adalah gabungan antara *dataset* bersih (*clean text*) dan *dataset* yang telah diobfuskasi (*obfuscated text*) untuk kedua kelas label, yang selanjutnya akan digunakan pada tahap pelatihan (*adversarial training*) dan pengujian model.



Gambar 4 Training & Evaluation

Gambar 4 menggambarkan alur pelatihan model *deep learning* hingga pemilihan model final untuk diintegrasikan ke dalam sistem. Proses dimulai dengan pelatihan awal menggunakan *hyperparameter* default pada dataset gabungan teks bersih dan termanipulasi *Unicode*.

Selanjutnya, dilakukan *tuning hyperparameter* dan *retraining* secara berulang untuk meningkatkan performa model. Jika terjadi peningkatan performa (misalnya F1-score naik >1%), maka model hasil *tuning* disimpan sebagai model terbaik sementara. Proses *tuning* dan *retraining* berlanjut hingga seluruh arsitektur (CNN, BiLSTM, IndoBERT) selesai dilatih. Setelah semua model selesai, dilakukan perbandingan model berdasarkan metrik *F1-score* tertinggi masing – masing arsitektur. Model dengan *F1-score* tertinggi kemudian dipilih sebagai model final, yang selanjutnya akan diimplementasikan ke *REST API* dan *browser extension*. Alur ini memastikan bahwa sistem deteksi menggunakan model dengan performa optimal hasil dari proses iteratif yang terstruktur.



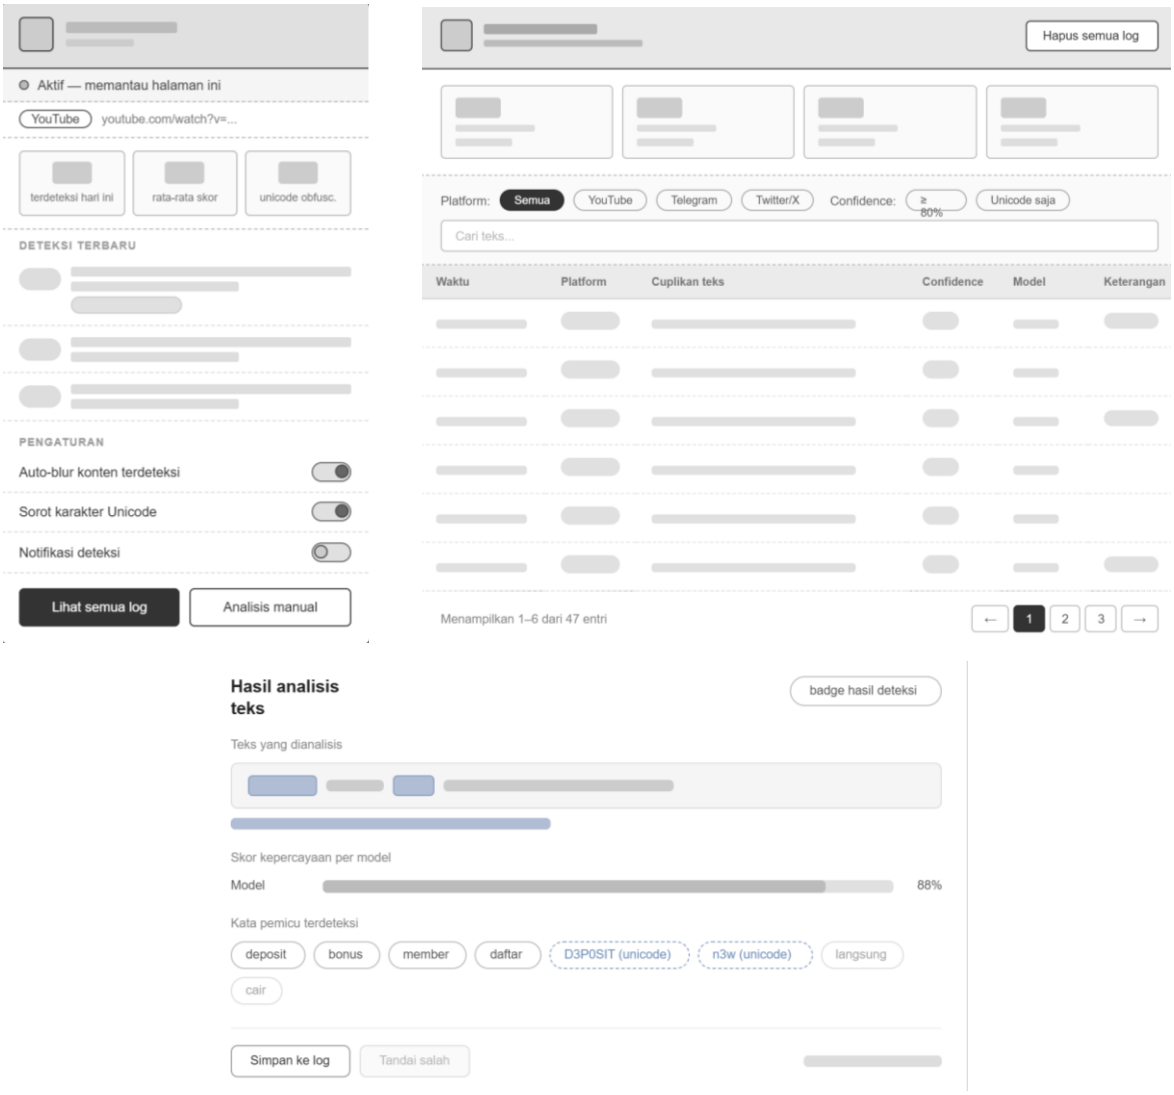
Gambar 5 Alur Sistem

Gambar 5 menggambarkan alur pengembangan sistem yang akan berfungsi sebagai *proof of concept* dari penelitian ini. Sistem *browser extension* bekerja secara otomatis mengikuti alur yang dimulai ketika pengguna membuka sebuah halaman *web*. Proses pertama yang terjadi adalah *extension* memindai seluruh elemen teks yang ada pada halaman tersebut. Hasil pemindaian kemudian dikirimkan sekaligus ke *backend* melalui *endpoint POST /predict/batch* dalam satu *request* tunggal, sehingga seluruh teks pada halaman diproses secara efisien tanpa membebani *server*.

Setelah *backend* mengembalikan hasil prediksi, *extension* melakukan pengecekan terhadap setiap label yang diterima. Apabila suatu teks berlabel Promosi Judol, *extension* secara otomatis menerapkan efek *blur* dan *overlay* peringatan pada elemen tersebut sehingga konten tidak langsung terlihat oleh pengguna. Sebaliknya, apabila teks berlabel Non Promosi Judol, elemen tersebut ditampilkan sebagaimana mestinya tanpa perubahan apapun.

Setelah seluruh teks selesai diproses, hasil deteksi diakumulasikan dan disimpan ke *browser storage* sebagai data statistik sesi. Data ini mencatat berapa banyak konten judol yang berhasil

diblokir selama pengguna menjelajahi halaman tersebut. Tahap terakhir adalah pemantauan berkelanjutan menggunakan *MutationObserver*. *Extension* terus memantau apakah ada konten baru yang muncul di halaman, misalnya akibat *scroll*, *lazy load*, atau pesan baru yang masuk secara *realtime*. Apabila konten baru terdeteksi, proses kembali berulang dari tahap pemindaian elemen teks. Apabila tidak ada konten baru, proses berhenti dan *extension* kembali ke mode *standby* hingga ada perubahan berikutnya.



Gambar 6 *Wireframe browser extension*

Gambar 6 menyajikan rancangan *wireframe* dari tiga komponen utama *browser extension* yang akan dikembangkan. Ketiga komponen tersebut adalah halaman *popup*, halaman log, dan antarmuka analisis manual. Rancangan ini bertujuan memberikan gambaran visual tentang tata letak dan alur interaksi pengguna. Dengan demikian, pengembangan antarmuka dapat dilakukan secara terarah sesuai kebutuhan sistem deteksi promosi judi *online*.

Halaman *popup* merupakan antarmuka utama yang muncul saat pengguna mengklik ikon *extension*. Halaman ini menampilkan status pemantauan *realtime* beserta platform yang sedang dibuka, seperti *YouTube*, *Telegram Web*, atau *Twitter/X*. Tiga kartu statistik menyajikan

ringkasan total deteksi hari ini, rata-rata skor kepercayaan, serta jumlah teks dengan manipulasi *Unicode*. *Feed* deteksi terbaru menampilkan tiga entri hasil prediksi lengkap dengan tingkat kepercayaan, cuplikan teks, dan *badge Unicode*. Di bagian bawah, tersedia *toggle* untuk mengaktifkan *auto-blur*, penyorotan karakter *Unicode*, dan notifikasi, serta tombol untuk membuka halaman log dan analisis manual.

Halaman *log* menyajikan seluruh riwayat deteksi dalam bentuk tabel yang berisi waktu, platform, cuplikan teks, tingkat kepercayaan, model yang digunakan, dan keterangan. Pengguna dapat melakukan pencarian teks tertentu serta menyaring entri berdasarkan platform atau rentang tingkat kepercayaan. Tersedia pula tombol untuk menghapus semua log jika diperlukan. Halaman ini dirancang untuk mendukung penelusuran historis dan evaluasi performa sistem secara lebih mendalam. Antarmuka analisis manual diaktifkan dengan memilih teks pada halaman *web*, lalu klik kanan dan memilih opsi "Analisis manual". *Card* hasil menampilkan *badge* label deteksi, teks lengkap, skor kepercayaan per model, serta daftar kata pemicu dengan penyorotan karakter *Unicode*. Pengguna dapat menyimpan hasil analisis ke dalam log atau melaporkan prediksi yang dianggap salah.

Pengembangan sistem dalam penelitian ini memanfaatkan sejumlah teknologi yang dipilih berdasarkan kesesuaiannya dengan kebutuhan setiap lapisan arsitektur. Pada tahap pengumpulan dan anotasi dataset, data teks dikumpulkan secara manual dari *public channel Telegram*, komentar *YouTube*, dan *Twitter/X*, kemudian diolah menggunakan *Python* sebagai bahasa pemrograman utama. Proses *preprocessing* teks mencakup normalisasi karakter dan *stemming* bahasa Indonesia menggunakan library PySastrawi. Pembuatan variasi *text obfuscation* berbasis Unicode dilakukan dengan memanfaatkan modul unicodedata bawaan Python untuk manipulasi *homoglyph substitution*, *Unicode character substitution*, dan penyisipan *invisible character*.

Pada lapisan pelatihan model, arsitektur CNN dan BiLSTM diimplementasikan menggunakan *framework TensorFlow* dengan *Keras API*, sedangkan arsitektur *IndoBERT* diimplementasikan menggunakan *PyTorch* melalui *library Hugging Face Transformers* dengan memanfaatkan *pretrained model* IndoBERT dari repositori *Hugging Face Hub*. Seluruh proses pelatihan, evaluasi, dan eksperimen *adversarial training* dikelola menggunakan Python di lingkungan *Jupyter Notebook* untuk memudahkan eksplorasi dan dokumentasi eksperimen.

Pada lapisan *backend*, model terbaik yang telah dilatih diimplementasikan melalui *REST API* yang dibangun menggunakan *framework FastAPI*. *API* ini menyediakan dua *endpoint* utama, yaitu *POST /predict* untuk inferensi satu teks dan *POST /predict/batch* untuk pemrosesan batch elemen DOM secara efisien. *Backend* dijalankan menggunakan *Uvicorn* sebagai ASGI *server* dan dikemas dalam lingkungan virtual *Python* untuk menjaga isolasi dependensi.

Pada lapisan *frontend*, sistem *browser extension* dikembangkan menggunakan standar *Manifest V3* (MV3) dengan teknologi *web* dasar yaitu *HTML, CSS*, dan *JavaScript*. Modul *content_script.js*

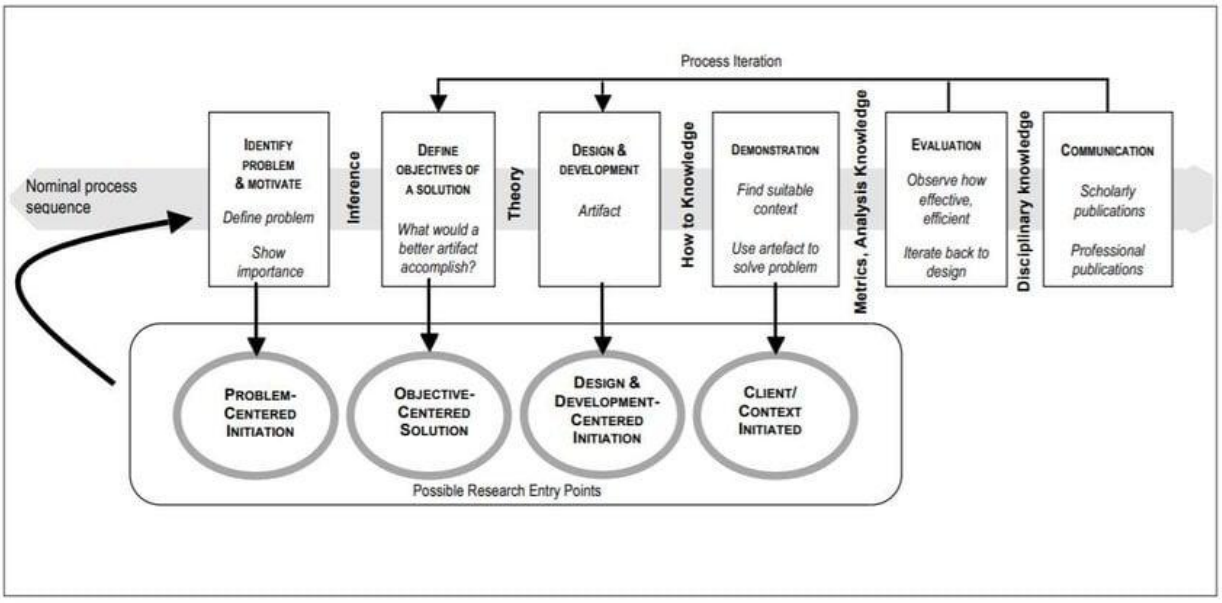
bertanggung jawab atas pemindaian DOM dan pemantauan konten baru menggunakan *Web API MutationObserver*, sedangkan *background.js* berperan sebagai *service worker* yang mengelola komunikasi antara *content script* dan *backend API*. Antarmuka pengguna berupa *popup* dikembangkan sebagai halaman HTML mandiri yang berkomunikasi dengan *service worker* melalui *chrome.runtime.sendMessage()*. Data statistik dan riwayat deteksi disimpan secara lokal di browser pengguna menggunakan *chrome.storage.local*, sementara pengaturan pengguna disinkronisasi menggunakan *chrome.storage.sync*. Seluruh pengembangan dan pengujian *browser extension* dilakukan menggunakan *Google Chrome* dengan memanfaatkan fitur *developer mode* untuk memuat *extension* secara lokal.

Metodologi Peneltian

Penelitian ini merupakan penelitian pengembangan (*Research and Development*) yang menggunakan *Design Science Research Methodology* (DSRM) yang sudah disesuaikan dengan pengembangan teknologi informasi (TI). Pendekatan ini dipilih karena menyediakan tahapan yang terstruktur untuk merancang, membangun, mendemonstrasikan, dan mengevaluasi artefak TI guna memecahkan masalah praktis (Peffers dkk., 2007).

Namun, karena DSRM tidak memberikan alur kerja yang rinci untuk pengembangan model *machine learning*, penelitian ini memadukannya dengan metode SEMMA (*Sample, Explore, Modify, Model, Assess*) pada tahap perancangan dan pengembangan artefak. SEMMA dipilih karena kesesuaiannya dengan alur kerja *data mining*, dukungan terhadap proses iteratif untuk *tuning hyperparameter*, serta kebutuhan untuk menciptakan dataset dengan variasi manipulasi Unicode (McCue, 2015).

Penelitian ini menggunakan jalur masuk *Problem-Centered Initiation* karena dipicu oleh temuan masalah di platform digital dan keterbatasan model pada literatur yang sudah ada.



Gambar 7 Tahapan *Design Science Research*

A. Tahapan Penelitian

Berdasarkan gambar 7 berikut tahapan penelitian yang akan dilakukan:

1. Identifikasi Masalah dan Motivasi

   Tahapan ini bertujuan mendefinisikan masalah penelitian secara spesifik dan menjustifikasi nilai dari solusi yang akan dibuat. Pada penelitian ini, masalah yang ingin diidentifikasi adalah kerentanan model *deep learning* modern terhadap manipulasi karakter *Unicode*. Manipulasi ini sengaja digunakan untuk menghindari sistem deteksi otomatis. Motivasinya adalah kebutuhan untuk mengembangkan sistem deteksi promosi judol berbahasa Indonesia yang tahan terhadap manipulasi teks tersebut.

2. Mendefinisikan Tujuan Solusi

   Tahap ini berfokus pada penetapan tujuan solusi yang akan dikembangkan berdasarkan definisi masalah dan kelayakannya. Pada tahap ini, peneliti merumuskan arah pengembangan sistem dengan mengeksplorasi arsitektur *deep learning* yang paling optimal serta penerapan pendekatan *adversarial training* untuk meningkatkan ketahanan terhadap manipulasi *Unicode* pada teks promosi judol. Selain itu, ditentukan kriteria evaluasi yang akan digunakan untuk mengukur performa model, yaitu menggunakan metrik *F1-score* sebagai acuan karena mampu menyeimbangkan *precision* dan *recall* pada tugas klasifikasi *biner*.

3. Desain dan Pengembangan

   Pada tahap ini akan dikembangkan artefak berupa model deep learning yang akan dilatih menggunakan adversarial training, *REST API* berbasis *FastAPI*, dan *browser extension* berbasis *Manifest V3*. Pengembangan model akan mengikuti metode SEMMA.

   Setelah model *final* diperoleh, peneliti akan mengimplementasikan *REST API* menggunakan *FastAPI*. Selanjutnya, akan dikembangkan *browser extension* dengan *content script* yang mampu memindai elemen teks pada halaman *web*, mengirimkan teks ke *API*, menerima label, dan menerapkan efek *blur* serta *overlay* peringatan pada elemen yang terdeteksi sebagai promosi judi. *Extension* juga akan dilengkapi *MutationObserver* untuk mendeteksi konten baru akibat *scroll, lazy load,* atau pesan *realtime*.

4. Demonstrasi

   Demonstrasi akan dilakukan untuk menunjukkan bahwa artefak dapat digunakan dalam skenario nyata. Peneliti akan menjalankan *REST API* secara lokal, kemudian memasang *browser extension* pada peramban *Chrome*. Selanjutnya, akan dibuka halaman *web Telegram*, *YouTube*, dan *Twitter/X* yang telah disisipi teks promosi judi dan teks normal. Proses deteksi otomatis akan diamati teks promosi judi yang terdeteksi harus tampak kabur (*blur*) disertai peringatan, sedangkan teks normal tetap utuh. Karakter *Unicode* yang termanipulasi akan diberi *highlight*. Selain itu, demonstrasi juga akan mencakup pengujian

pemrosesan konten baru dengan melakukan scroll atau mengirim pesan secara real-time. Seluruh proses akan direkam dalam bentuk video dan tangkapan layar.

5. Evaluasi

   Evaluasi akan dilakukan menggunakan pendekatan *black-box testing* yang terstruktur, tanpa melihat implementasi internal. Fokus evaluasi adalah sistem secara keseluruhan, mencakup model, *API*, dan *browser extension*.

   Model final akan dievaluasi pada data *test* yang terpisah. Metrik yang akan dihitung meliputi akurasi, presisi, *recall*, dan *F1-score*. Hasil ini akan digunakan untuk melaporkan kemampuan deteksi sistem. Untuk keperluan perbandingan antar arsitektur, akan disajikan *F1-score* tertinggi yang dicapai masing-masing arsitektur selama proses *tuning*. Analisis kesalahan juga akan dilakukan dengan mengambil sampel prediksi yang salah untuk mengidentifikasi jenis manipulasi *Unicode* yang paling sulit dikenali.

   API akan diuji secara fungsional dengan mengirimkan berbagai permintaan. Setiap uji akan dicatat apakah respons yang diberikan sesuai dengan spesifikasi (kode *HTTP*, struktur *JSON*). Selain itu, akan dilakukan pengukuran waktu respons dengan mengirim 100 permintaan *batch* secara berulang, akan dihitung waktu rata – rata dan persentil ke-95.

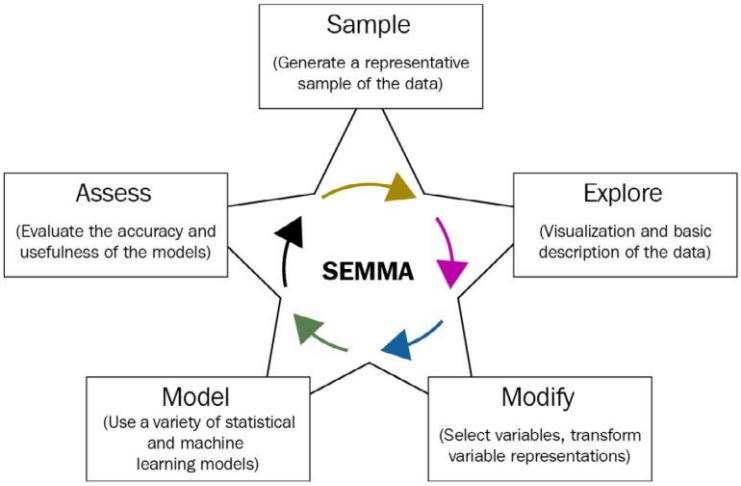
   Extension akan diuji melalui serangkaian skenario fungsional, misalnya membuka halaman tanpa teks judol, halaman dengan satu teks judol, halaman dengan banyak teks judol, kemunculan konten baru karena *scroll*, pesan *realtime*, serta pengujian kompatibilitas pada peramban *Chrome* dan *Edge*. Setiap skenario akan dinilai berhasil atau gagal. Selanjutnya, akan dilakukan pengukuran kuantitatif pada halaman simulasi yang berisi 50 teks promosi judol (termanipulasi *Unicode*) dan 50 teks normal. Metrik yang akan diukur meliputi *detection success rate* (persentase teks judol yang berhasil diblur), *false positive rate* (persentase teks normal yang salah diblur), waktu pemindaian DOM, waktu respons *API*, dan waktu total *end-to-end*.

   Untuk memvalidasi sistem dari perspektif manusia yang memahami karakteristik promosi judi online, akan melibatkan ahli di bidang moderasi konten. Para ahli akan diminta menguji sistem dan memberikan penilaian menggunakan kuesioner *System Usability Scale* (SUS) yang telah diadaptasi.

6. Komunikasi

   Tahap terakhir ini mengomunikasikan masalah, artefak, desain, serta efektivitas sistem kepada audiens akademis. Dalam penelitian ini, tahap komunikasi direalisasikan melalui penulisan dan penyusunan laporan skripsi pada akhir masa penelitian, guna memberikan kontribusi pengetahuan akademis terkait peningkatan ketahanan sistem NLP berbahasa Indonesia terhadap teknik manipulasi *Unicode*. Seluruh artefak (kode sumber model, *API*,

dan *browser extension*) akan dipublikasikan dalam repositori *GitHub*. Video demonstrasi sistem juga akan disertakan sebagai lampiran.



Gambar 8 Tahapan SEMMA

B. Tapahapan Pengembangan Model

Berdasarkan gambar 8, berikut tahapan pengembangan model yang akan dilakukan:

1. *Sample*

   Peneliti akan mengumpulkan teks berbahasa Indonesia dari public channel dan grup *Telegram*, komentar *YouTube*, serta *Twitter/X*. Target minimal 2.000 sampel dengan distribusi seimbang antara teks promosi judi online dan teks non-promosi.

2. *Explore*

   Data yang terkumpul akan difilter untuk menghapus duplikat, teks terlalu pendek (kurang dari empat kata), teks non-Indonesia, serta konten hanya berupa URL. Anotasi akan dilakukan oleh dua anotator independen dengan pedoman pelabelan yang disusun sebelumnya. Tingkat kesepakatan antar anotator akan diukur menggunakan *Cohen's Kappa*.

3. *Modify*

   Untuk merepresentasikan manipulasi *Unicode*, peneliti akan membuat dataset yang mengandung teks dengan variasi karakter *Unicode* (misalnya penggantian huruf Latin dengan huruf dari skrip lain atau penyisipan karakter tak terlihat) pada intensitas sedang (sekitar 30% karakter diubah). Dataset akhir untuk pelatihan merupakan gabungan dari teks asli (bersih) dan teks termanipulasi dengan rasio 1:1. Data kemudian akan dibagi menjadi *training* (80%), validasi (10%), dan *test* (10%).

5. *Model*

   Peneliti akan melatih tiga arsitektur *deep learning*, yaitu CNN, BiLSTM, dan IndoBERT, menggunakan pendekatan *adversarial training*. Pelatihan akan dilakukan pada dataset yang telah disiapkan. Setiap arsitektur akan melalui proses *tuning hyperparameter* secara iteratif untuk memperbaiki kemampuan model.

6. *Assess*

Peneliti akan melakukan evaluasi internal terhadap model yang telah dilatih, antara lain dengan memeriksa indikasi *overfitting* melalui perbandingan performa pada data *training* dan validasi, serta menentukan *epoch* optimal berdasarkan *learning curve*. Metrik yang digunakan dalam evaluasi ini meliputi akurasi, presisi, *recall*, dan *F1-score*. Model dengan *F1-score* tertinggi dari setiap arsitektur akan dicatat sebagai model terbaik untuk arsitektur tersebut. Hasil evaluasi internal ini akan menjadi acuan sebelum model diintegrasikan ke dalam sistem.

Referensi

Boucher, N., Shumailov, I., Anderson, R., & Papernot, N. (2021). *Bad Characters: Imperceptible NLP Attacks*.

Chen, H., & Ji, Y. (2022). *Adversarial Training for Improving Model Robustness? Look at Both Prediction and Interpretation*.

Cooper, P., Blanco, E., & Surdeanu, M. (2025). The Lies Characters Tell: Utilizing Large Language Models to Normalize Adversarial Unicode Perturbations. *Findings Ofthe Association for Computational Linguistics*, 18932–18944.

Kaur, S., Singh, S., & Kaushal, S. (2024). Deep learning-based approaches for abusive content detection and classification for multi-class online user-generated data. *International Journal of Cognitive Computing in Engineering*, *5*, 104–122. https://doi.org/10.1016/j.ijcce.2024.02.002

Le, T., Lee, J., Yen, K., Hu, Y., & Lee, D. (2022). *Perturbations in the Wild: Leveraging Human-Written Text Perturbations for Realistic Adversarial Attack and Defense*.

McCue, C. (2015). Process Models for Data Mining and Predictive Analysis. Dalam *Data Mining and Predictive Analysis* (2nd ed., hlm. 51–74). https://doi.org/10.1016/B978-0-12-800229-2/00004-3

Peffers, K., Tuunanen, T., Rothenberger, M. A., & Chatterjee, S. (2007). A Design Science Research Methodology for Information Systems Research. *Journal of Management Information Systems*, *24*(3), 45–77. https://doi.org/10.2753/MIS0742-1222240302

Prasetya Kristiadi, D., & Samuel. (2025). Deteksi Teks Promosi Judi Online Menggunakan Ai Dengan Kombinasi NLP Dan Deep Learning. *Jurnal Sistem Informasi dan Teknologi (SINTEK)*, *5*(2), 179–185. https://doi.org/10.56995/sintek.v5i2.179

Purnamadewi, Y. R., & Zahra, A. (2025). Enhancing detection of zero-day phishing email attacks in the Indonesian language using deep learning algorithms. *Bulletin of Electrical Engineering and Informatics*, *14*(1), 505–512. https://doi.org/10.11591/eei.v14i1.8759

Raharjo, B., Rudjiono, & Fitrianto, Y. (2024). Prediction and Detection of Scam Threats on

Digital Platforms for Indonesian Users Using Machine Learning Models. *Journal of Technology Informatics and Engineering*, *3*(3), 350–369. https://doi.org/10.51903/jtie.v3i3.208

Sarabamoun, E. (2025). *Special-Character Adversarial Attacks on Open-Source Language Model*.

Shah, B. M. (2025). Adversarial Attacks in NLP for Abuse Detection Systems. *European Journal of Artificial Intelligence and Machine Learning*, *4*(3), 24–28. https://doi.org/10.24018/ejai.2025.4.3.64

Subramanian, M., Easwaramoorthy Sathiskumar, V., Deepalakshmi, G., Cho, J., & Manikandan, G. (2023). A survey on hate speech detection and sentiment analysis using machine learning and deep learning models. Dalam *Alexandria Engineering Journal* (Vol. 80, hlm. 110–121). Elsevier B.V. https://doi.org/10.1016/j.aej.2023.08.038

Wu, J., & Yeung, D.-Y. (2023). *SCAT: Robust Self-supervised Contrastive Learning via Adversarial Training for Text Classification*.

Yang, Y., Liu, X., & He, K. (2024). *Fast Adversarial Training against Textual Adversarial Attacks*.

Rencana Jadwal Penelitian

Bulan	Minggu	Tahapan	Aktivitas Utama	Output / Target
1	1	Aktivitas 1 dan 2 DSRM (Identifikasi Masalah & Tujuan Solusi)	Studi literatur sistematis, identifikasi *research gap*, perumusan masalah dan tujuan penelitian, penentuan kriteria evaluasi awal	Dokumen rumusan masalah, tujuan penelitian, dan kerangka teoritis
1	2-4	SEMMA: Sample & Explore	Pengumpulan teks dari Telegram , YouTube, Twitter/X. Filter awal (hapus duplikat, teks pendek, non-Indonesia, hanya URL). Anotasi anotator dan *Cohen's Kappa*.	Dataset berlabel minimal 2.000 sampel, nilai *Cohen's Kappa* terdokumentasi

2	1-2	SEMMA: Modify	Pembuatan manipulasi *Unicode* intensitas sedang (30% karakter). Gabungan teks bersih dan termanipulasi. Pembagian data *training* 80%, validasi 10%, *test* 10%.	Dataset bersih dan termanipulasi siap pakai, terbagi *training*/validasi/*test*
2	3-4	SEMMA: Model (iterasi awal)	Pelatihan tiga arsitektur model dengan *adversarial training* menggunakan *hyperparameter* default. Evaluasi awal pada data validasi.	Model awal untuk ketiga arsitektur, catatan *F1-score* awal
3	1-2	SEMMA: Model (tuning iteratif)	*Tuning hyperparameter* secara bergantian untuk setiap arsitektur. Ulangi *training* dan evaluasi validasi. Bandingkan *F1-score* dengan model sebelumnya.	Model terbaik untuk CNN, BiLSTM, IndoBERT.
3	3	SEMMA: Assess & Pemilihan Model Final	Perbandingan *F1-score* tertinggi ketiga arsitektur. Pilih satu model final dengan *F1-score* tertinggi. Cek *overfitting*, tentukan epoch optimal.	Model *final* terpilih, dan dokumentasi hasil evaluasi

3	4	Aktivitas 3 DSRM (lanjutan) – Implementasi *API* dan *Extension*	Implementasi model *final* ke *REST API*. Pengembangan *browser extension*.	*REST API* berfungsi, *browser extension* versi awal siap uji
4	1-2	Aktivitas 4 DSRM – Demonstrasi	Menjalankan *API* dan *extension* di *browser*. Demonstrasi di halaman *Telegram Web*, *YouTube*, *Twitter/X* yang disisipi teks judol serta teks normal. Rekam video dan screenshot. Uji pemrosesan konten baru.	Video demonstrasi, dokumen hasil uji fungsionalitas
4	3	Aktivitas 5 DSRM – Evaluasi	*Black-box testing*: evaluasi model pada data *test*. Evaluasi *API*. Evaluasi *extension.* Evaluasi ahli.	Hasil evaluasi lengkap (tabel, grafik, skor SUS)
4	4	Aktivitas 6 DSRM – Komunikasi	Penyusunan laporan skripsi. Pembuatan repositori GitHub (dataset, notebook training, API, extension). Penyusunan video demonstrasi sebagai lampiran. Revisi akhir.	Laporan skripsi final, repositori publik, video lampiran

Pengalaman

Penulis memiliki latar belakang yang relevan dengan topik penelitian ini melalui pengalaman di bidang *deep learning* dan pemrosesan teks. Penulis telah menyelesaikan program *Machine Learning Developer* dari *ID Camp x Dicoding* serta kelas Belajar *Fundamental Deep Learning* dari Dicoding yang mencakup materi *Natural Language Processing*, klasifikasi teks, LSTM, dan *deployment model machine learning* dengan total lebih dari 110 jam pembelajaran. Kompetensi ini diperkuat dengan sertifikasi *Microsoft Certified: Azure AI Fundamentals* dan penyelesaian *Mastering AI Bootcamp*.

Selain pembelajaran terstruktur, penulis juga memiliki pengalaman langsung dalam pengembangan proyek berbasis NLP, termasuk sistem *QnA* otomatis berbasis RAG yang memanfaatkan teknik *text chunking, vector embedding*, dan integrasi model bahasa besar, serta proyek klasifikasi teks yang memberikan pemahaman praktis mengenai pemrosesan dan representasi bahasa. Pengalaman-pengalaman tersebut menjadi landasan teknis yang kuat bagi penulis dalam menjalankan penelitian ini, khususnya dalam membangun dan mengevaluasi model *deep learning* untuk deteksi teks promosi judol berbahasa Indonesia yang mengalami manipulasi karakter berbasis *Unicode*.